

# Aprendizado Semi-Supervisionado Baseado em Grafos

Seminário da Matéria SCC5882

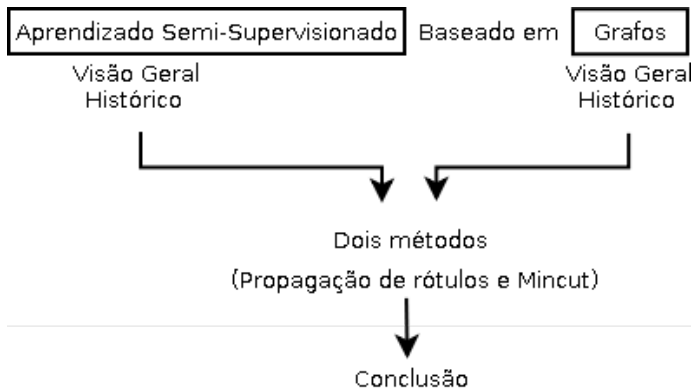
Professores: Dr. Zhao Liang e Dr. Alneu de Andrade Lopes

Aluno: Renato Fabbri

6 de julho de 2010

- 1 Apresentação
  - Sumário
  - Resumo
- 2 Introdução
  - Aprendizado Semi-Supervisionado
  - Grafos e Redes Complexas
- 3 Aprendizado Semi-Supervisionado em Grafos
  - Propagação de Rótulo
  - Mincut
- 4 Conclusão
- 5 Principais Referências

# Resumo



- 1 Apresentação
  - Sumário
  - Resumo
- 2 **Introdução**
  - **Aprendizado Semi-Supervisionado**
  - **Grafos e Redes Complexas**
- 3 Aprendizado Semi-Supervisionado em Grafos
  - Propagação de Rótulo
  - Mincut
- 4 Conclusão
- 5 Principais Referências

# A - Definições (1)

- Aprendizado Supervisionado - treinamento somente com os dados rotulados

# A - Definições (1)

- Aprendizado Supervisionado - treinamento somente com os dados rotulados
- Aprendizado não Supervisionado - utilizados somente dados não rotulados

# A - Definições (1)

- Aprendizado Supervisionado - treinamento somente com os dados rotulados
- Aprendizado não Supervisionado - utilizados somente dados não rotulados
- Aprendizado Semi-Supervisionado - utilização tanto dos dados rotulados quanto dos não rotulados.

# A - Definições (2)

- Classificação Semi-Supervisionada, CSS. (Clusterização forçada não é foco)



# A - Definições (2)

- Classificação Semi-Supervisionada, CSS. (Clusterização forçada não é foco)
- Indutivo e Transdutivo.


# A - Interesse

- Criança aprendendo as coisas (animais).

# A - Interesse


- Criança aprendendo as coisas (animais).
- Dados rotulados podem ser poucos ou custosos.

# A - Caso 1



**Figura:** Forma em que a CSS auxilia na classificação. Fonte: Zhu, X. and Lafferty, J. and Rosenfeld, R., 2005

## A - Caso 2



# A - Breve Histórico

- Primeiros: Modelos de Mistura.

# A - Breve Histórico

- Primeiros: Modelos de Mistura.
- Primeiros: Self-Training (self-teaching e bootstrapping).

# A - Breve Histórico

- Primeiros: Modelos de Mistura.
- Primeiros: Self-Training (self-teaching e bootstrapping).
- Mais recentes: Co-training e SVM transdutivo.



# A - Breve Histórico

- Primeiros: Modelos de Mistura.
- Primeiros: Self-Training (self-teaching e bootstrapping).
- Mais recentes: Co-training e SVM transdutivo.
- Mais recentes: Métodos baseados em grafos.

- 1 Apresentação
  - Sumário
  - Resumo
- 2 **Introdução**
  - **Aprendizado Semi-Supervisionado**
  - **Grafos e Redes Complexas**
- 3 Aprendizado Semi-Supervisionado em Grafos
  - Propagação de Rótulo
  - Mincut
- 4 Conclusão
- 5 Principais Referências

# G & RC - Definição (1)

- Conjunto de objetos, alguns ligados.

# G & RC - Definição (1)

- Conjunto de objetos, alguns ligados.
- Objetos  $\rightarrow$  nós ou vértices. Ligações  $\rightarrow$  arestas.

# G & RC - Definição (1)

- Conjunto de objetos, alguns ligados.
- Objetos  $\rightarrow$  nós ou vértices. Ligações  $\rightarrow$  arestas.
- Visualmente  $\rightarrow$  pontos e linhas.

# G & RC - Variações

- Arestas Direcionadas.

# G & RC - Variações

- Arestas Direcionadas.
- Pesos nas arestas.

# G & RC - Variações

- Arestas Direcionadas.
- Pesos nas arestas.
- Mais de um tipo de aresta.



# G & RC - Variações

- Arestas Direcionadas.
- Pesos nas arestas.
- Mais de um tipo de aresta.
- Atributos quaisquer associados às arestas e aos nós.

# G & RC - Exemplos Clássicos

- Regular.

# G & RC - Exemplos Clássicos

- Regular.
- Completo (*click*).

# G & RC - Exemplos Clássicos

- Regular.
- Completo (*click*).
- Conectado.

# G & RC - Exemplos Clássicos

- Regular.
- Completo (*click*).
- Conectado.
- Randômico.

# G & RC - Exemplos Clássicos

- Regular.
- Completo (*click*).
- Conectado.
- Randômico.
- trivial, nulo, etc.

# G & RC - Medidas mais Comuns

- Grau.

# G & RC - Medidas mais Comuns

- Grau.
- Força.



# G & RC - Medidas mais Comuns

- Grau.
- Força.
- Entrada e Saída.

# G & RC - Rede Complexa

- Grafo de grandes dimensões.
- Casos triviais - RC randômica e regular.

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.
- "Grafo" Nature - Silvester 1878.

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.
- "Grafo" Nature - Silvester 1878.
- Grafos, topologia, álgebra - Lei de Kirchoff

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.
- "Grafo" Nature - Silvester 1878.
- Grafos, topologia, álgebra - Lei de Kirchoff
- Teorias probabilísticas

# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.
- "Grafo" Nature - Silvester 1878.
- Grafos, topologia, álgebra - Lei de Kirchoff
- Teorias probabilísticas
- RC naturais - propriedades não triviais - LE, PM.



# G & RC - Breve Histórico

- Euler - "Konigsberg Bridge problem".
- Cayley - Química.
- "Grafo" Nature - Silvester 1878.
- Grafos, topologia, álgebra - Lei de Kirchoff
- Teorias probabilísticas
- RC naturais - propriedades não triviais - LE, PM.
- Neurociência, Física, Linguística, Computação, etc.

- 1 Apresentação
  - Sumário
  - Resumo
- 2 Introdução
  - Aprendizado Semi-Supervisionado
  - Grafos e Redes Complexas
- 3 Aprendizado Semi-Supervisionado em Grafos**
  - Propagação de Rótulo
  - Mincut
- 4 Conclusão
- 5 Principais Referências

# CSS em G

- Algoritmo de regularização.
- Mincut
- Propagação de Rótulo.
- Modelos de Mistura.
- Máxima Entropia.
- ETC.

- 1 Apresentação
  - Sumário
  - Resumo
- 2 Introdução
  - Aprendizado Semi-Supervisionado
  - Grafos e Redes Complexas
- 3 Aprendizado Semi-Supervisionado em Grafos**
  - Propagação de Rótulo
  - Mincut
- 4 Conclusão
- 5 Principais Referências

# PR - Conceção

- Vizinho mais próximo  $\rightarrow$  propaga mais fácil.

# PR - Conceção

- Vizinho mais próximo  $\rightarrow$  propaga mais fácil.
- Rótulos fixos nos rotulados de antemão.

# PR - Conceção

- Vizinho mais próximo  $\rightarrow$  propaga mais fácil.
- Rótulos fixos nos rotulados de antemão.
- Estes "emanam" os seus rótulos.

# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.



# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.
- $y \in 1 \dots C$  com  $C$  o número de classes.

# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.
- $y \in 1 \dots C$  com  $C$  o número de classes.
- $x_{l+1} \dots x_{l+u}$ .

# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.
- $y \in 1 \dots C$  com  $C$  o número de classes.
- $x_{l+1} \dots x_{l+u}$ .
- Geralmente  $l \ll u$ .

# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.
- $y \in 1 \dots C$  com  $C$  o número de classes.
- $x_{l+1} \dots x_{l+u}$ .
- Geralmente  $l \ll u$ .
- Seja  $n = l + u$

# Convenções e Exposição do Problema (1)

- $(x_1, y_1) \dots (x_l, y_l)$  os dados rotulados.
- $y \in 1 \dots C$  com  $C$  o número de classes.
- $x_{l+1} \dots x_{l+u}$ .
- Geralmente  $l \ll u$ .
- Seja  $n = l + u$
- $L$  e  $U$  denotam os dados rotulados e não rotulados, respectivamente

## Convenções e Exposição do Problema (2) - Notas

- Cada classe de  $C$  presente em ao menos 1 elemento.

# Convenções e Exposição do Problema (2) - Notas

- Cada classe de  $C$  presente em ao menos 1 elemento.
- Método Transdutivo.

# Convenções e Exposição do Problema (3) - Obtenção do Grafo

- Completo.



# Convenções e Exposição do Problema (3) - Obtenção do Grafo

- Completo.
- $w_{ij} = \exp(-\frac{\|x_i - x_j\|^2}{\alpha^2})$

# Convenções e Exposição do Problema (3) - Obtenção do Grafo

- Completo.
- $w_{ij} = \exp(-\frac{\|x_i - x_j\|^2}{\alpha^2})$
- $\alpha$  é um *hiperparâmetro*

## Convenções e Exposição do Problema (4) - Transição

- $P_{ij}$  é a probabilidade de transição do nó  $i$  para o nó  $j$  (passagem do rótulo)

## Convenções e Exposição do Problema (4) - Transição

- $P_{ij}$  é a probabilidade de transição do nó  $i$  para o nó  $j$  (passagem do rótulo)
- $P_{ij} = P(i \rightarrow j) = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$

# Convenções e Exposição do Problema (5) - Últimas Definições

- Matriz de rótulos  $Y_L$ ,  $I \times C$ , cuja *iésima* linha possui 1 na coluna correspondente à classe do dado  $x_i$ .

# Convenções e Exposição do Problema (5) - Últimas Definições

- Matriz de rótulos  $Y_L$ ,  $I \times C$ , cuja  $i$ ésima linha possui 1 na coluna correspondente à classe do dado  $x_i$ .
- $f$  uma matriz  $n \times C$  em que cada linha pode ser interpretada como uma distribuição de probabilidade sobre os rótulos.

## Convenções e Exposição do Problema (5) - Tarefa!

A tarefa consiste em computar os rótulos dos nós todos (na verdade somente dos não rotulados)

# O Algoritmo de Propagação de Rótulo

- Propague  $f \leftarrow Pf$ . (todos os nós propagam o seu rótulo para os seus vizinhos)
- Mantenha os dados rotulados iniciais  $f_L = Y_L$ . (assegura que os rótulos dos nós inicialmente rotulados não sejam sobrescritos)
- Repita do passo 1 até que o algoritmo convirja.



# PR - Convergência (1)

$$f = \begin{pmatrix} f_L \\ f_U \end{pmatrix} \quad (1)$$

$$\begin{bmatrix} P_{LL} & P_{LU} \\ P_{UL} & P_{UU} \end{bmatrix} \quad (2)$$

$$f_U \leftarrow P_{UU} f_U + P_{UL} Y_L \quad (3)$$

$$f_u = \lim_{n \rightarrow \infty} [(P_{UU})^n f_U^0 + (\sum_{i=1}^n (P_{UU})^{(i-1)}) P_{UL} Y_L] \quad (4)$$

## PR - Convergência (2)

$$f_u = \lim_{n \rightarrow \infty} [(P_{UU})^n f_U^0 + (\sum_{i=1}^n (P_{UU})^{(i-1)}) P_{UL} Y_L] \quad (5)$$

$$(P_{UU})^n f_U^0 \rightarrow 0 \quad (6)$$

$$\exists \gamma < 1 : \sum_{j=1}^u (P_{UU})_{ij} \leq \gamma, \forall i = 1 \dots u \quad (7)$$


Portanto:

$$\sum_j (P_{UU})_{ij}^n \leq \gamma^n \quad (8)$$


Então:

$$f_u = (I - P_{UU})^{-1} P_{UL} Y_L \quad (9)$$


# PR - Exemplo 1 (1)



# PR - Exemplo 1 (2)



# PR - Exemplo 1 (3)



## PR - Exemplo 2 (1)




Figura: Dados originais, 2 rotulados, 184 não rotulados

# PR - Exemplo 1 (2)




Figura: Dados espiralados rotulados utilizando-se knn.

# PR - Exemplo 1 (2)




Figura: Dados espiralados rotulados utilizando propagação de rótulos.



# Mincut - Conceção

- Objetos parecidos devem ficar juntos.
- Seccionamento por separações de custos mínimos.

# Mincut - Convenções e Exposição do Problema

- rotulados  $L$  e não rotulados  $U$ .

# Mincut - Convenções e Exposição do Problema

- rotulados  $L$  e não rotulados  $U$ .
- $L_+$  os positivos;  $L_-$  os negativos.

# Mincut - Convenções e Exposição do Problema

- rotulados  $L$  e não rotulados  $U$ .
- $L_+$  os positivos;  $L_-$  os negativos.
- $v_+$  e  $v_-$

# O Algoritmo de Propagação de Mincut

- $G = (V, E)$ , onde  $V = L \cup U$  e  $E \subseteq V \times V$
- $e \in E$  é associado um peso  $w(e)$
- $w(v_1, v_2) = \infty, \forall v_1, v_2 \in L_+$  e  $w(v_1, v_2) = \infty, \forall v_1, v_2 \in L_-$ .
- Função de atribuição de pesos, denotada por  $w$ .
- Determinamos o conjunto de arestas com a menor soma de pesos que, se removidas, separam todos os  $v_+$  dos  $v_-$ . (Corte mínimo)
- Por fim, rotulamos como positivos todos os vértices em  $V_+$  e como negativos todos os vértices em  $V_-$ .

# Calibragem do Mincut

- $w$  é sem dúvida o crucial neste algoritmo.
- **Mincut-3**
- **Mincut- $\delta$ , Mincut- $\delta_0$ , Mincut- $\delta_{\frac{1}{2}}$ , Mincut- $\delta_{opt}$**

# Mincut - Problemas

- Difícil Calibragem.
- Casos de poucos exemplos rotulados

# Mincut - Desempenho Comparativo (1)

DATASET	$ L  \&  U $	NUMBER OF FEATURES	MINCUT				ID3	3-NN
			MINCUT-3	MINCUT- $\delta_{opt}$	MINCUT- $\delta_0$	MINCUT- $\delta_{1/2}$		
MUSH	20+1000	22	82.1	<b>97.7</b>	<b>97.7</b>	97.0	93.3	91.1
MUSH*	20+1000	22	74.2	<b>88.7</b>	56.9	<b>87.0</b>	80.8	83.3
TAE	10+100	5	86.0	<b>99.0</b>	96.0	<b>97.0</b>	86.0	80.0
TAE*	10+100	5	76.0	<b>96.0</b>	86.0	<b>94.0</b>	76.0	62.0
VOTING	45+390	16	89.1	<b>91.3</b>	66.1	83.3	86.4	<b>89.6</b>
MUSK	40+200	166	73.0	<b>92.5</b>	91.0	<b>92.5</b>	83.5	87.0
PIMA	50+718	8	63.8	<b>72.3</b>	48.8	<b>72.3</b>	70.0	68.1
IONO	50+300	34	71.0	81.6	78.0	77.6	<b>88.6</b>	69.6
BUPA	45+300	6	53.3	<b>59.3</b>	48.0	41.7	<b>55.3</b>	52.7
MI	124+432	6	70.0	64.4	64.4	64.4	<b>98.6</b>	81.1
MII	169+432	6	<b>68.6</b>	67.2	57.2	67.2	67.9	63.6
MIII*	122+432	6	79.1	80.6	64.8	80.6	<b>94.4</b>	83.6

Figura: Mincut com alguns valores para  $\delta$  e comparação com outros métodos.



## Mincut - Desempenho Comparativo (2)




Figura: Variação do erro com o Delta.

## Mincut - Desempenho Comparativo (3)




Figura: Comparação do erro entre mincut e kNN com a variação de exemplos rotulados  $\delta_{opt}$ .

## Mincut - Desempenho Comparativo (4)




Figura: Comparação do erro entre mincut e kNN com a variação de exemplos não

# Conclusão

- Com segurança se as classes são clusterizadas entre si.
- Na falta de dados rotulados
- Seguindo a distribuição dos dados evitam o critério único da proximidade dos dados rotulados.
- Melhor que o kNN para os casos que vimos.
- Complexidade simples-moderada.

# Referências Principais

- Zhu, X. and Lafferty, J. and Rosenfeld, R. "Semi-supervised learning with graphs.", 2005
- Zhu, X. and Ghahramani, Z., "Learning from labeled and unlabeled data with label propagation.", 2002
- Blum, A. and Chawla, S., "Learning from labeled and unlabeled data using graph mincuts", 2001

FIM.

FIM.